Lenguajes y Autómatas I

Juan Pablo Rosas Baldazo

Reporte de proyecto 2

Alfonso Guerrero Contreras
de control16480211

07/10/2018

Tabla de contenido

Introducción

Las expresiones regulares son útiles para reconocer los patrones dentro de cadenas de texto.

En este documento se verán tres programas, todos con similitudes, ya que trabajan con cadenas de caracteres.

Dos son para reconocer si una dirección de correo electrónico dada esta estructurada de forma correcta. Uno de los programas será enteramente propio, mientras que el otro implementará el uso de una expresión regular para verificar correos. Incluye una prueba para verificar cual es más eficaz.

El último programa será una implementación del Algoritmo KMP(Knuth-Morris-Pratt) y probar que funciona.

Validar formato de un correo electrónico mediante método propio

Descripción

Primero se ingresa el correo que se va a verificar mediante un input que guardaremos en una variable, para después mandarla a la función que lo verificara

```
correo = input("Inserta la direccion de correo electronico")
verificarCorreo(correo)
```

La verificación en si es muy simple, primero verificamos que todos los caracteres son en letras minúsculas

```
if correo.islower():
```

de lo contrario es una dirección de correo invalido

```
else:
   print("correo falso")
```

a continuación, verificamos que exista una arroba (@)

```
if "@" in correo:
```

si no existe el correo es invalido

```
else:
   print("correo falso")
```

si existe separamos la cadena con el @ como marca y las guardamos en variables

```
usuario,dominio = correo.split("@")
```

a continuación, revisamos que en la cadena que contiene el dominio exista un punto

```
if "." in dominio:
```

si existe entonces el correo esta estructurado de forma correcta, de lo contrario es un correo no valido

```
if "." in dominio:
    print ("Correo valido")
else:
    print ("Correo falso")
```

Pruebas

El equipo en que se harán las pruebas es un laptop HP Pavilon x360

- Procesador AMD A8-6410 APU 2.00GHz
- Graficos Rendon R5 Graphics
- Windows 10 Home de 64 bits
- 4 GB de memoria RAM

Para probar el tiempo de ejecución de la aplicación, usare diferente longitud en las cadenas.

Pruebas de longitud de la cadena

Las pruebas de longitud.

Cadena	longitud	Resultado
alfonso@gmail.com	17	1.567763090133667
alfonsoguerrero@gmail.com	25	1.9024724960327148
alfonsoguerrerocontreras@gmail.com	34	1.669835090637207
Alfonsoguerrerocontreras1234@gmail.com	38	1.5697710514068604
Alfonsoguerrerocontreras12345678@gmail.com	42	1.9694550037384033

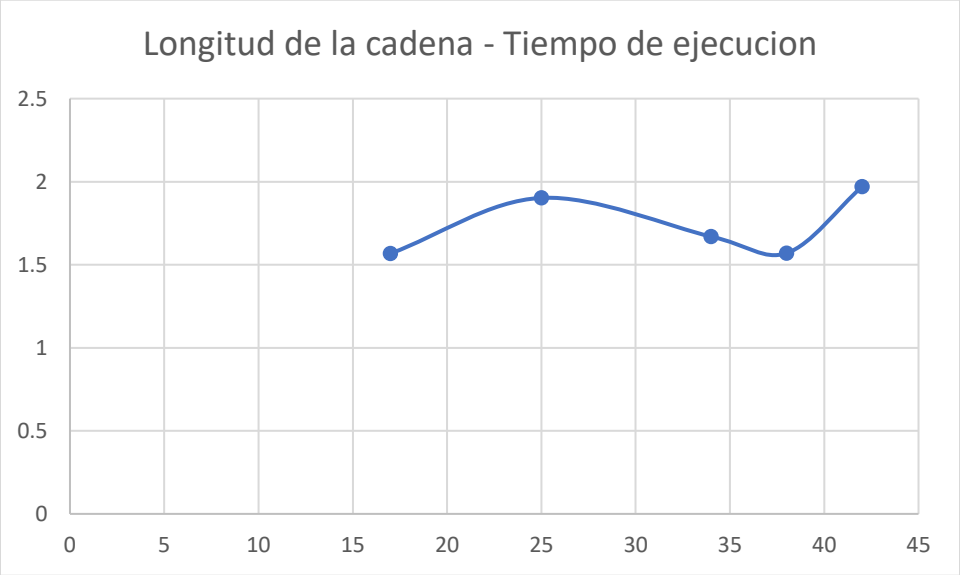

Como podemos observar, la longitud de la cadena no es relevante, ya que la variación en segundos es muy baja.

Pruebas de cantidad de iteraciones

Esta vez tomaremos uno de los casos anteriores y lo repetiremos 10 veces para observar las diferencias entre el tiempo de ejecución con los mismos parámetros.

Cadena	longitud	Iteración	Resultado
alfonso@gmail.com	17	1	1.3185153007507324
alfonso@gmail.com	17	2	1.4434807300567627
alfonso@gmail.com	17	3	1.3442604541778564
alfonso@gmail.com	17	4	1.6786532402038574
alfonso@gmail.com	17	5	1.4536638259887695
alfonso@gmail.com	17	6	1.6602065563201904
alfonso@gmail.com	17	7	1.4181671142578125
alfonso@gmail.com	17	8	1.8332490921020508
alfonso@gmail.com	17	9	1.8020215034484863
alfonso@gmail.com	17	10	1.3776590824127197

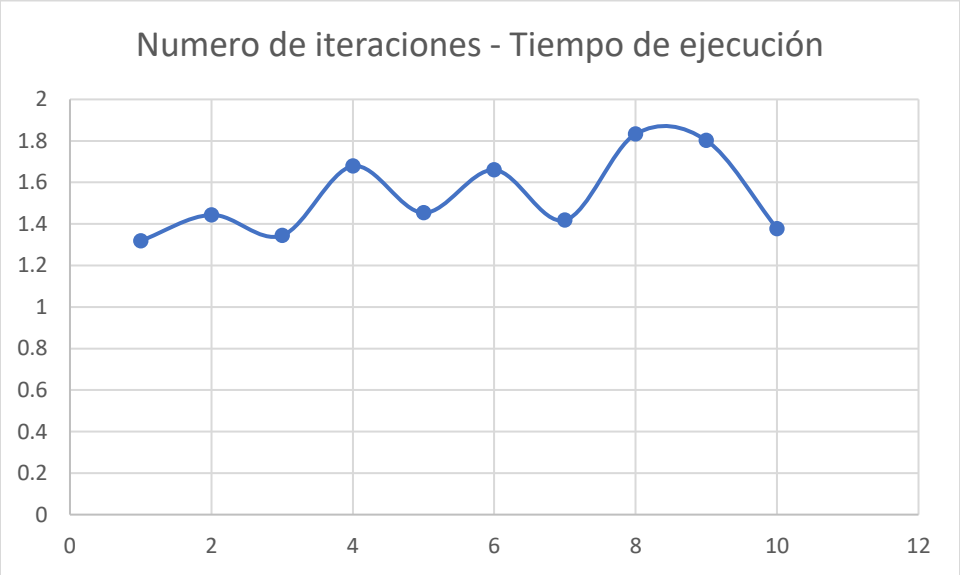

- En esta prueba podemos observar que, aun cuando los parámetros son iguales, el procesador los ejecutara a diferente velocidad dependiendo de que este haciendo en ese momento.

Validar formato de correo electrónico mediante una expresión regular.

Descripción

Primero se ingresa el correo que se va a verificar mediante un input que guardaremos en una variable, para después mandarla a la función que lo verificara

```
correo = input("Inserta la direccion de correo electronico")
verificarCorreo(correo)
```

en validar correo tenemos la expresión regular que nos permitirá revisar si la estructura del correo es adecuada

```
'^[(a-z0-9\_\-\.)]+@[(a-z0-9\_\-\.)]+\.[(a-z)]{2,15}$'
```

Verificamos si la cadena enviada cuenta con estos requisitos colocándola en un if, de ser asi entonces es una dirección de correo valida

```
if re.match('^[(a-z0-9\_\-\.)]+@[(a-z0-9\_\-\.)]+\.[(a-
z)]{2,15}$',correo.lower()):
   print ("Correo correcto")
```

de lo contrario es una dirección de correo electrónico no valida

```
else:
   print ("Correo incorrecto")
```

Pruebas

El equipo en que se harán las pruebas es un laptop HP Pavilon x360

- Procesador AMD A8-6410 APU 2.00GHz
- Graficos Rendon R5 Graphics
- Windows 10 Home de 64 bits
- 4 GB de memoria RAM

Para probar el tiempo de ejecución de la aplicación, usare diferente longitud en las cadenas.

Pruebas de longitud de cadena

Primero probaremos como reacciona el sistema cuando se le ingresan cada vez más datos.

Cadena	longitud	Resultado
alfonso@gmail.com	17	1.5301012992858887
alfonsoguerrero@gmail.com	25	1.4993832111358643
alfonsoguerrerocontreras@gmail.com	34	1.6678433418273926
Alfonsoguerrerocontreras1234@gmail.com	38	1.3646585941314697
Alfonsoguerrerocontreras12345678@gmail.com	42	1.629441499710083

- Al incrementar la longitud de la cadena, se nota un ligero incremento en el tiempo de ejecución.

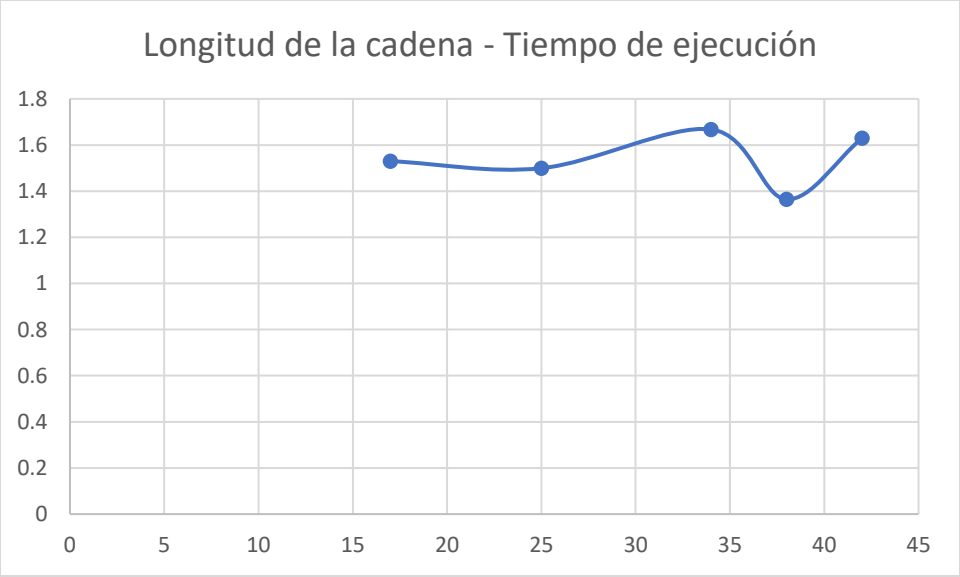

Pruebas de cantidad de iteraciones

Esta vez tomaremos uno de los cazos anteriores y lo repetiremos 10 veces para observar las diferencias entre el tiempo de ejecución con los mismos parámetros.

Cadena	longitud	Iteración	Resultado
alfonso@gmail.com	17	1	1.4516689777374268
alfonso@gmail.com	17	2	1.0698623657226562
alfonso@gmail.com	17	3	1.3995728492736816
alfonso@gmail.com	17	4	0.9732472896575928
alfonso@gmail.com	17	5	1.052912712097168
alfonso@gmail.com	17	6	1.180114507675171
alfonso@gmail.com	17	7	1.1998951435089111
alfonso@gmail.com	17	8	1.0866975784301758
alfonso@gmail.com	17	9	0.995703935623169
alfonso@gmail.com	17	10	1.249755859375

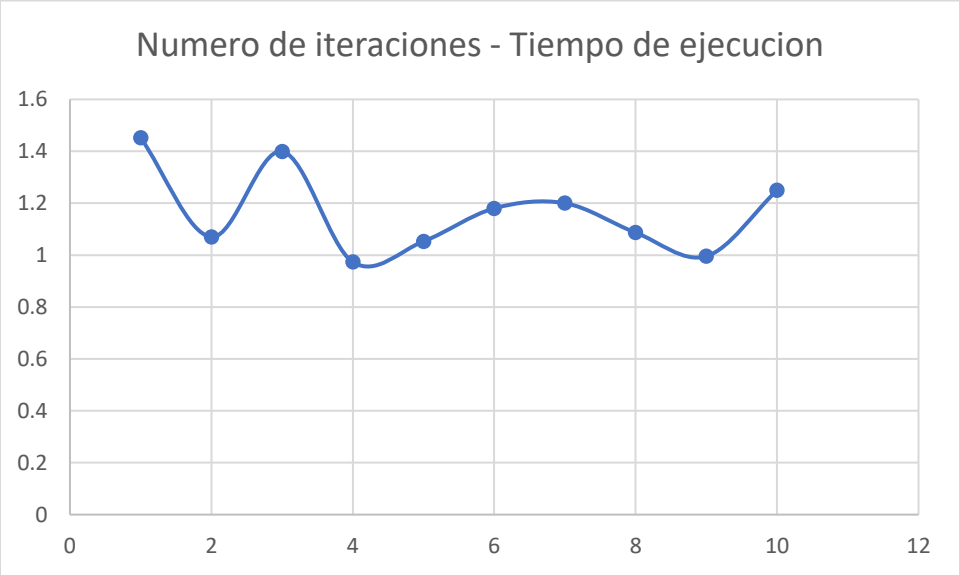

- Al igual que en la prueba de iteraciones de la otra función, podemos observar que, aun cuando los parámetros son iguales, el procesador los ejecutara a diferente velocidad dependiendo de que este haciendo en ese momento.

Comparación de resultados de ambos verificadores de correo electrónico

Longitud de cadena

Lenguaje regular		Propio	
longitud	Resultado	longitud	Resultado
17	1.5301012992858887	17	1.567763090133667
25	1.4993832111358643	25	1.9024724960327148
34	1.6678433418273926	34	1.669835090637207
38	1.3646585941314697	38	1.5697710514068604
42	1.629441499710083	42	1.9694550037384033

Como podemos observar, los tiempos, aunque muy similares, son mayores en el programa que realice por mi cuenta que en el que utiliza el algoritmo regular.

Numero de iteraciones

Lenguaje regular		Propio	
Iteración	Resultado	Iteración	Resultado
1	1.4516689777374268	1	1.3185153007507324
2	1.0698623657226562	2	1.4434807300567627
3	1.3995728492736816	3	1.3442604541778564
4	0.9732472896575928	4	1.6786532402038574
5	1.052912712097168	5	1.4536638259887695
6	1.180114507675171	6	1.6602065563201904
7	1.1998951435089111	7	1.4181671142578125
8	1.0866975784301758	8	1.8332490921020508
9	0.995703935623169	9	1.8020215034484863
10	1.249755859375	10	1.3776590824127197

De nuevo podemos observar que el tiempo de ejecución al repetir la misma cadena múltiples veces es menor en la aplicación que usa un lenguaje regular.

Algoritmo KMP

Descripción

El algoritmo KMP consiste en crear una tabla de fallos, para saber cuantos espacios saltar al haber una discrepancia en la cadena de búsqueda de acuerdo con el patrón que estamos buscando.

Primero le damos la cadena y el patrón a buscar y lo mandamos

```
T = input("Inserta el texto.")
P = input("Inserta el patron a buscar dentro del texto.")

kmp(P, T)
```

Veamos la construcción de la tabla de fallos, que analiza el patrón para saber cuantos espacios pueden ser saltados.

```
def tabla_fallos(P):
```

definimos el largo del patrón y la dimensión de la tabla

```
l_p = len(P)
k = 0
table = [0] * l_p
```

iniciamos un ciclo que recorra el patrón

```
for q in range(1, l_p):
```

Se compara un fragmento de la cadena donde se busca con un fragmento de la cadena que se busca, y esto nos da un sitio potencial para que haya una nueva coincidencia.

```
while P[k] != P[q] and k > 0:
       k = table[k - 1]
   if P[k] == P[q]:
       k += 1
   table[q] = k
```

Regresa la tabla con los saltos (1) menos el ultimo carácter

```
return table[:-1]
```

A continuación, veremos el módulo de búsqueda que usa la tabla de fallos

```
def kmp(P, T):
```

primero definimos las variables que nos ayudaran

```
m = 0 salta dentro del texto y encuentra la posicion que se busca
i = 0 indice que recorre la palabra
pos = 0 es para saber cuando la palabra no existe
l_p = len(P)largo del patron
l_t = len(T)largo del texto
```

después se confirma que el texto es mas grande que el patrón que se buscara

```
if(l_t >= l_p):
```

se genera la tabla de fallos

```
tabla = tabla fallos(P)
```

empieza ciclo para recorrer las posiciones del texto siempre que la posision de salto y el índice no exedan el largo del texto y patron respectivamente

```
while((m<l_t) and (i<=l_p)):
```

busca las posision en que hay una coincidencia e incrementa el índice

```
if(P[i] == T[m+i]):
    if(i == (l_p-1)):
        pos = pos + 1
        print ("esta en la posicion %s" %m)
        return
    i= i+1
```

de lo contrario el índice salta a la posision indicada en la tabla de fallos

```
else:
   m = m + i - tabla[i]
   if(i>0):
      i = tabla[i]
```

si la posision es icual a 0, no se encontró coincidencia

```
if pos == 0:
      print ("no se encuentra")
```

Pruebas

El equipo en que se harán las pruebas es un laptop HP Pavilon x360

- Procesador AMD A8-6410 APU 2.00GHz
- Graficos Rendon R5 Graphics
- Windows 10 Home de 64 bits
- 4 GB de memoria RAM

Para probar el tiempo de ejecución de la aplicación, usare diferente longitud en las cadenas.

Pruebas de longitud de cadena

Primero probaremos cómo reacciona el sistema cuando se incrementa el tamaño de la cadena.

Cadena	Patrón	longitud	Resultado
aaaaaaaaab	aaab	10	6.111125421524048
abcabcabcabacf	bacf	14	6.1273353099823
bbbbbbaabbbaaab	aaab	17	7.106204195022583
10010101111011000123	0123	21	7.1199138832092285
ccnmcceerteeheddddddaaab	aaab	25	7.131639719009399

- Al incrementar la longitud de la cadena, se nota un ligero incremento en el tiempo de ejecución.

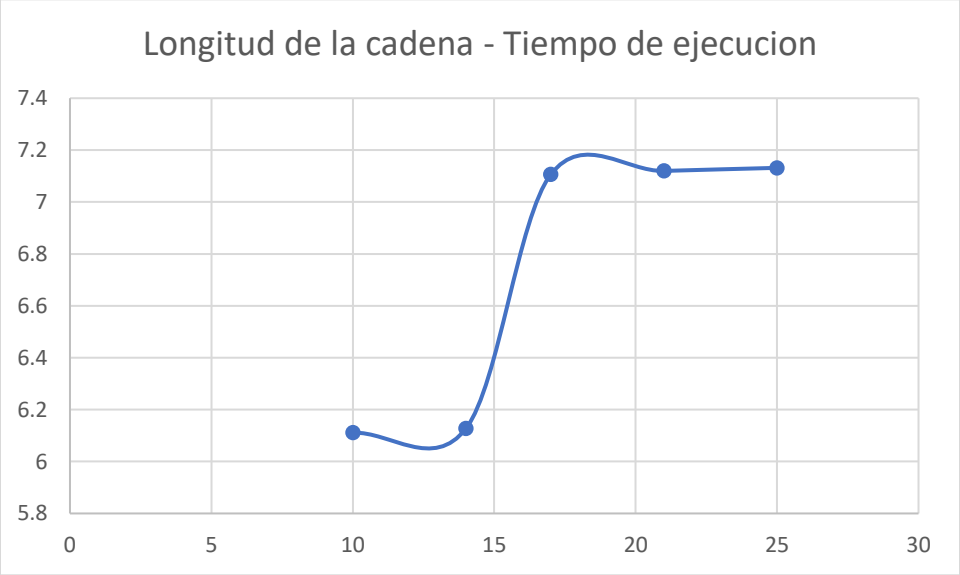

Pruebas de longitud de patrón

Esta vez cambiaremos la longitud del patrón y observaremos el comportamiento del sistema.

Cadena	Patrón	longitud	Resultado
aaaaaaaaaaaaaaaaaaab	aaab	4	1.6675162315368652
aaaaaaaaaaaaaaaaaaab	aaaaaab	7	1.410728931427002
aaaaaaaaaaaaaaaaaaab	aaaaaaaaab	10	1.4886062145233154
aaaaaaaaaaaaaaaaaaab	aaaaaaaaaaaab	13	1.5345427989959717
aaaaaaaaaaaaaaaaaaab	aaaaaaaaaaaaaab	16	1.568472146987915

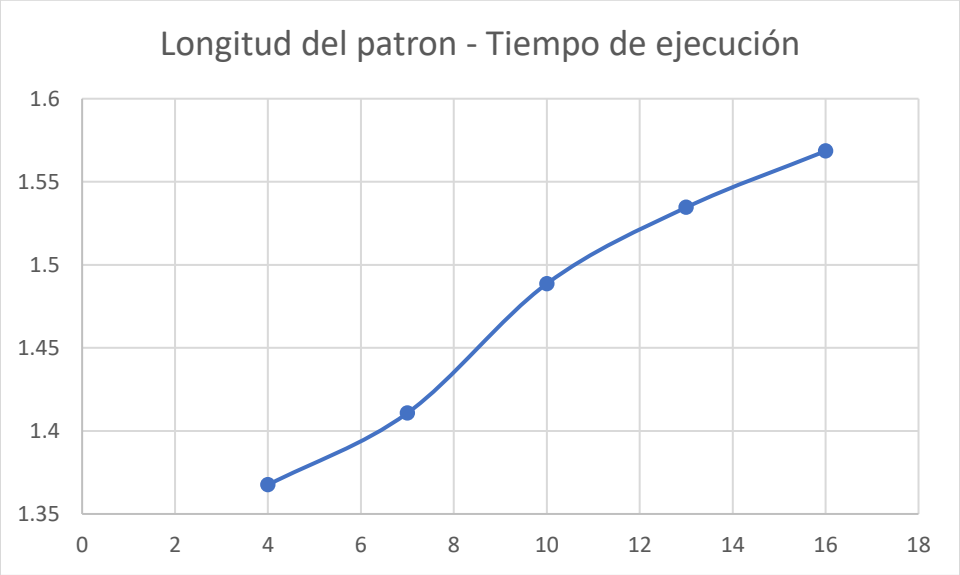

- Se puede observar que entre más grande es el patrón más tiempo tomo en ejecutarse el programa. Sin embargo, el crecimiento entre un intento y otro no es muy grande.

Conclusión

El uso de expresiones regulares vivió mucho más corto el código para la validación de correo electrónico. También redujo el tiempo de ejecución, incluso si solo fue por unos 0.1 segundos aproximadamente.

Trabajar con expresiones regulares ya diseñadas sin duda facilita las cosas, sin embargo, en programas simples, encontrar dicha expresión regular puede tomar mas tiempo que hacerlo sin estas.

En las aplicaciones complicadas y en las que debemos cuidar cada recurso que tenemos es donde brilla el uso de las expresiones regulares.

El KMP fue mucho más difícil de comprender, y de probar. En la primera prueba debido a que variaban los textos y los patrones tarde mas tiempo en introducir los datos, mientras que, en la segunda, puse en memoria el texto y solo introduje la cadena a mano. Esto resultó en tiempos muy diferentes, sin embargo, la variación de estos tiempos con respecto a su incremento en la longitud de los datos introducidos es similar. Por lo tanto, se incrementa mas o menos el mismo tiempo en ejecución sin importar cuál de los dos parámetros aumente.

Fuentes

https://docs.python.org/3/library/

https://www.lawebdelprogramador.com/codigo/Python/2040-Validar-cuenta-de-correo.html

http://cecilia-urbina.blogspot.com/2013/02/string-matching.html